

Clasificación de los Niveles de Fósforo en Caña Panelera utilizando Diferentes modelos

Agricultura Predictiva

Heidy Andrea Toro Monsalve, Liseth Natalia Loaiza Rojas

Introducción

La agricultura predictiva es una rama de la analítica de datos que emplea técnicas de aprendizaje automático para transformar información agrícola en herramientas de apoyo para la toma de decisiones. A partir de bases de datos, este enfoque permite identificar patrones, modelar relaciones entre variables y generar predicciones sobre el comportamiento de cultivos, suelos, precios y sistemas productivos.

Una de las áreas en las que se está implementando con mayor potencial este tipo de tecnologías es el análisis de resultados de laboratorio de suelos, ya que dichos análisis contienen información fundamental sobre las propiedades químicas y físicas que determinan la fertilidad y la disponibilidad de nutrientes para las plantas. Variables como el pH, la materia orgánica, la conductividad eléctrica, el fósforo y el potasio permiten evaluar el estado nutricional del suelo y establecer estrategias de manejo más eficientes (Brady & Weil, 2017).

Tradicionalmente, la interpretación de estos resultados ha dependido del conocimiento técnico del agrónomo y del uso de rangos de referencia. Sin embargo, cuando se dispone de grandes volúmenes de datos históricos, es posible aplicar algoritmos de aprendizaje automático para descubrir relaciones complejas entre variables y clasificar el comportamiento de nutrientes clave. Esto facilita la identificación de deficiencias, la estimación de requerimientos de fertilización y la simulación de escenarios productivos bajo diferentes condiciones de manejo (Kamilaris & Prenafeta-Boldú, 2018).

En este contexto, el cultivo de caña panelera representa un caso de estudio de gran relevancia en Colombia, debido a su importancia económica y social para miles de pequeños y medianos productores. La productividad de este cultivo depende en gran medida de la adecuada disponibilidad de nutrientes en el suelo, especialmente de elementos como el fósforo y el potasio, los cuales intervienen en procesos esenciales como el desarrollo radicular, el transporte de azúcares y la formación de biomasa (Osorio, 2014)

Objetivo general

- Desarrollar varios modelos de clasificación para categorizar los niveles de fósforo Bray II y potasio intercambiable en suelos destinados al cultivo de caña panelera.

objetivos específicos

- Obtener y preprocesar una base de datos real de análisis de suelos para el cultivo de caña panelera, realizando procesos de limpieza, selección de variables relevantes y tratamiento de valores faltantes.
- Generar una base de datos sintética a partir de la información real y de condiciones agronómicas ideales, con el fin de comparar resultados de los modelos.

Metodología

1. Caso real

1.1. Obtención de la base de datos

Inicialmente, se realizó una búsqueda de información en diferentes plataformas de datos abiertos de Colombia relacionadas con el sector agropecuario. Como resultado, se seleccionó una base de datos de análisis de suelos para cultivo de caña disponible en la plataforma de AGROSAVIA.

1.2. Preprocesamiento de los datos

Posteriormente, se realizó un proceso de limpieza y acondicionamiento de los datos con el fin de preparar el conjunto para el entrenamiento de modelos de machine learning. Durante esta etapa se trataron valores nulos, se estandarizaron variables categóricas y se generaron nuevas variables relacionadas con fertilización y manejo agronómico.

Las variables categóricas fueron convertidas a formatos adecuados para su procesamiento y algunas variables asociadas a fertilización fueron transformadas en variables binarias, permitiendo representar la aplicación de nutrientes como fósforo, potasio, cal y materia orgánica.

1.3. Tratamiento de valores atípicos

Se realizó un análisis de distribución de las variables numéricas, identificando asimetrías y colas largas, principalmente en variables como Fósforo Bray, conductividad eléctrica y potasio intercambiable.

Debido a que los valores atípicos representaban una proporción importante del dataset, no se consideró adecuado eliminarlos completamente, ya que esto reduciría significativamente la cantidad de información disponible. Por esta razón, se aplicó un tratamiento mediante percentiles.

Para las variables más afectadas por valores extremos se utilizó un cappeo al percentil 97, mientras que para las demás variables los valores superiores al percentil 99 fueron reemplazados por el valor correspondiente a dicho percentil. Este procedimiento permitió reducir el efecto de valores extremos sin perder la variabilidad natural presente en los datos de suelo.

1.4. Transformación de la variable objetivo

Inicialmente, el análisis fue planteado como un problema de regresión para predecir los valores de fósforo en el suelo. Sin embargo, después de diferentes pruebas, se decidió transformar la variable objetivo en un problema de clasificación multiclase.

La variable Fósforo Bray fue dividida en tres categorías: bajo, medio y alto. Aunque inicialmente se consideraron rangos agronómicos ideales para el cultivo, finalmente las clases fueron definidas utilizando percentiles de la distribución de los datos reales, con el fin de obtener un mejor balance entre categorías.

Para ello, el límite de la primera clase se estableció utilizando el cuantil correspondiente al 33 % de los datos, mientras que el límite de la segunda clase se definió con el cuantil del 66 %. De esta manera, se obtuvieron tres categorías con una distribución más equilibrada, facilitando el entrenamiento y evaluación de los modelos de clasificación.

1.5. Escalado y preparación de los datos

Posteriormente, el conjunto de datos fue dividido en entrenamiento y prueba utilizando una proporción 80/20. Las variables numéricas fueron escaladas mediante RobustScaler, debido a su capacidad para reducir el impacto de valores atípicos presentes en el dataset.


Adicionalmente, se realizó un análisis de componentes principales (PCA) sobre las variables numéricas, con el fin de reducir dimensionalidad y analizar la variabilidad de los datos.

1.6. Entrenamiento de modelos

Finalmente, se entrenaron y compararon diferentes modelos de machine learning para la clasificación de los niveles de fósforo del suelo. Entre los modelos evaluados se encuentran Random Forest, Support Vector Machine, XGBoost, K-Nearest Neighbors y CatBoost.

El desempeño de los modelos fue evaluado mediante métricas de clasificación como Accuracy, reportes de clasificación y matrices de confusión, con el objetivo de identificar el modelo con mejor capacidad predictiva para clasificar los niveles de fósforo en el suelo.

2. Generación de datos sintéticos



Se realizó una revisión bibliográfica para identificar los rangos óptimos de las principales variables químicas y edáficas asociadas al cultivo de caña panelera, tomando como referencia las variables seleccionadas del conjunto de datos original. Entre las variables consideradas se incluyeron el tiempo de establecimiento, la topografía, el drenaje, el riego, la aplicación

de fertilizantes, el pH agua:suelo, la materia orgánica, la conductividad eléctrica, el fósforo Bray II y el potasio intercambiable. Los rangos agronómicos utilizados se basaron en la literatura especializada para el manejo de suelos tropicales y fertilidad en caña, donde se reportan valores óptimos de pH entre 5,5 y 6,8, materia orgánica entre 2,5 y 5,5 %, fósforo Bray II entre 20 y 40 mg/kg y potasio intercambiable entre 0,30 y 1,20 cmol(+)/kg.

Con base en estos rangos, se construyó un conjunto de datos sintético de 3.000 registros utilizando la librería `numpy.random` en Python, la cual permite generar valores aleatorios controlados dentro de distribuciones previamente definidas. Posteriormente, se asignaron distribuciones de probabilidad y pesos a los valores clasificados como bajos, óptimos y altos según los rangos reportados en la literatura, con el fin de generar un dataset más variable y representativo de diferentes condiciones del suelo, evitando que el modelo presentara una tendencia al sobreentrenamiento.

Para la generación de los datos sintéticos se mantuvo la estructura del conjunto de datos original y se definieron relaciones coherentes entre las variables, de manera que factores como el pH, la materia orgánica, el riego y la fertilización influyeran sobre los niveles de fósforo y potasio, reproduciendo el comportamiento esperado de los nutrientes en el suelo.

Posteriormente, la variable Fósforo Bray II fue transformada en una variable categórica utilizando rangos agronómicos definidos de la siguiente manera: **bajo** para valores menores a 20 mg/kg, **óptimo** para valores entre 20 y 40 mg/kg y **alto** para valores superiores a 40 mg/kg. Esta transformación permitió convertir el problema en una tarea de clasificación supervisada, cuyo objetivo fue evaluar el desempeño de diferentes algoritmos de aprendizaje automático para identificar correctamente la categoría nutricional del fósforo en los datos sintéticos.

Resultados

Después del tratamiento de valores atípicos mediante percentiles, las variables numéricas presentaron distribuciones más estables, reduciendo las colas extremas observadas principalmente en Fósforo Bray, conductividad eléctrica y potasio intercambiable. Esto

permitió disminuir posibles sesgos durante el entrenamiento de los modelos y mejorar la representación general de los datos (figura 1).




Figura 1. Distribución de los datos de tipo numéricos y scatter plot por clases.

Posteriormente, se entrenaron diferentes modelos de clasificación para predecir los niveles de fósforo del suelo, obteniendo accuracy entre 0.50 y 0.58 (Tabla 1). Aunque los resultados no fueron altos, evidencian el potencial del machine learning para apoyar la predicción de rangos de nutrientes del suelo a partir de variables químicas y agronómicas.

El mejor desempeño fue obtenido por CatBoost, con un accuracy de 58 % y una precisión de 69 % para la clase de bajos niveles de Fósforo Bray. Los modelos XGBoost y Random Forest optimizado también mostraron desempeños competitivos, con accuracies cercanos al 54 %.

Por otro lado, la reducción de variables y la aplicación de PCA disminuyeron el desempeño de los modelos, indicando pérdida de información relevante para la clasificación.

Tabla 1. Accuracy de los diferentes modelos entrenados

Model	Nombre OVERALL	Accuracy	Class 0 Precision	Class 1 Precision	Class 2 Precision
0	RandomForestClassifier (Inicial)	0.52	0.59	0.40	0.56
1	RandomForestClassifier (con PCA)	0.52	0.56	0.46	0.53
2	RandomForestClassifier (Optimizado)	0.54	0.63	0.43	0.56
3	SVC (Inicial)	0.53	0.56	0.44	0.57
4	SVC (Optimizado con GridSearchCV)	0.50	0.53	0.38	0.55
5	XGBoostClassifier	0.54	0.64	0.42	0.57
6	KNeighborsClassifier	0.54	0.60	0.43	0.60
7	CatBoostClassifier	0.58	0.69	0.45	0.60
8	RandomForestClassifier (Reducido)	0.52	0.59	0.41	0.54
9	CatBoostClassifier (Reducido)	0.52	0.57	0.42	0.56

La matriz de confusión del modelo CatBoost (figura 2) muestra un mejor desempeño en las clases extremas de Fósforo Bray. La clase 0 presentó 126 muestras correctamente clasificadas y la clase 2 obtuvo 122 aciertos, evidenciando una buena capacidad del modelo para identificar niveles bajos y altos de fósforo.

Por otro lado, la clase intermedia (clase 1) presentó una mayor confusión, especialmente con la clase 2, lo que indica una similitud entre los niveles medios y altos de fósforo en las variables utilizadas para el entrenamiento. En general, los errores se concentran entre clases consecutivas, mostrando que el modelo logra diferenciar adecuadamente los extremos, pero presenta mayor dificultad en rangos intermedios.




Figura 2. Matriz de confusión del modelo *CatBoostClassifier*, que obtuvo un accuracy de 58 %

En general, los modelos presentaron un mejor desempeño en la clasificación de las categorías extremas de fósforo (baja y alta concentración), mientras que la clase intermedia mostró una mayor confusión entre categorías consecutivas. Esto evidencia la dificultad de separar rangos medios de Fósforo Bray debido a la similitud de las propiedades químicas y agronómicas presentes en las muestras de suelo.

Resultado datos sintéticos


Tabla 2.

	accuracy	precision	recall	f1-score
model				
randomforest (fosforo - initial)	0.986667	0.99	0.99	0.99
randomforest (fosforo - selected features)	0.986667	0.99	0.99	0.99
xgboost (fosforo)	0.985000	0.99	0.99	0.99
svc (fosforo)	0.965000	0.97	0.97	0.97
kneighbors (fosforo)	0.558333	0.60	0.56	0.57

Los resultados obtenidos muestran que los modelos basados en árboles de decisión presentaron el mejor desempeño en la clasificación de los niveles de fósforo. El algoritmo Random Forest alcanzó una exactitud de 98,67 %, con valores de precisión, recall y F1-score cercanos a 0,99, lo que indica una alta capacidad para identificar correctamente las categorías bajo, óptimo y alto. De manera similar, XGBoost obtuvo una exactitud de 98,50 %, confirmando que estos modelos son altamente efectivos para capturar las relaciones no lineales entre las variables del suelo y el estado nutricional del fósforo. Por su parte, SVC presentó un desempeño aceptable con una exactitud de 96,5 %, aunque ligeramente inferior a los modelos anteriores.

Classification Report para 'fosforo_category' (KNN):

	precision	recall	f1-score	support
Bajo	0.54	0.66	0.59	229
Óptimo	0.82	0.59	0.69	157
Alto	0.44	0.43	0.43	214
accuracy			0.56	600
macro avg	0.60	0.56	0.57	600
weighted avg	0.58	0.56	0.56	600



El modelo K-Nearest Neighbors (KNN) presentó el desempeño más bajo entre los algoritmos evaluados, con una exactitud de 55,8 % y un F1-score macro de 0,57. Este resultado indica que el modelo tuvo dificultades para clasificar correctamente las categorías de fósforo, especialmente en los casos correspondientes a la clase "Alto", la cual fue frecuentemente confundida con la categoría "Bajo". Esta situación se evidencia en la matriz de confusión, donde se observa un número considerable de errores entre estas dos clases.

El bajo desempeño de KNN puede explicarse porque este algoritmo basa su clasificación en la similitud entre observaciones cercanas, lo cual resulta menos efectivo cuando existen relaciones no lineales y solapamientos entre las variables del suelo.

Conclusión

Los resultados obtenidos demuestran que las variables químicas del suelo y de manejo agronómico contienen información relevante para clasificar los niveles de Fósforo Bray en cultivos de caña panelera. El tratamiento de valores atípicos mediante percentiles permitió conservar la variabilidad natural del suelo sin reducir significativamente el tamaño del dataset, mejorando la estabilidad durante el entrenamiento de los modelos.

Entre los algoritmos evaluados, CatBoost presentó el mejor desempeño general, evidenciando una mayor capacidad para manejar variables categóricas y relaciones no lineales presentes en los datos edáficos. Sin embargo, los resultados también muestran la complejidad de predecir propiedades químicas del suelo, especialmente en categorías intermedias, donde existe una alta similitud entre clases.

En general, el estudio evidencia el potencial del machine learning como herramienta de apoyo para el análisis y clasificación de propiedades químicas del suelo en sistemas agrícolas.

Bibliografía

Liakos, K. G., Busato, P., Moshou, D., Pearson, S., & Bochtis, D. (2018). *Machine Learning in Agriculture: A Review*. *Sensors*, 18(8), 2674. <https://www.mdpi.com/1424-8220/18/8/2674>

Brady, N. C., & Weil, R. R. (2017). *The Nature and Properties of Soils*. Pearson. <https://www.pearson.com/en-us/subject-catalog/p/the-nature-and-properties-of-soils/P200000003326>

Kamilaris, A., & Prenafeta-Boldú, F. X. (2018). *Deep Learning in Agriculture: A Survey*. *Computers and Electronics in Agriculture*, 147, 70–90. <https://www.sciencedirect.com/science/article/pii/S0168169917308803>

Osorio, N. W. (2014). *Manejo de Nutrientes en Suelos del Trópico*. Universidad Nacional de Colombia. <https://repositorio.unal.edu.co/handle/unal/70174>